КУРСОВАЯ РАБОТА / ПРОМЕЖУТОЧНЫЕ РЕЗУЛЬТАТЫ

Квантизация диффузионных моделей машинного обучения

Activation-aware RVQ для Stable Diffusion 1.5

Подъяблонский Егор Петрович

ВМК МГУ | 2026

Задача и границы исследования

Диффузионные модели требуют значительных ресурсов. В работе исследуется **post-training quantization (PTQ)** весов.

Исследовательская цель

Сохранить большую часть качества сильного векторного бейзлайна **VQDM**, но уменьшить время построения квантизованного представления.

Узкое место VQDM — совместный поиск комбинаций кодовых слов с помощью **beam search**.

Что квантуется сейчас

- U-Net модели **Stable Diffusion 1.5**.
- `mid_block`: **18 Linear/Conv2d-слоёв**; также проверяется набор из 16 слоёв без двух `time_emb_proj`.
- **Только веса, без fine-tuning.**

Представленные далее результаты — для 18 слоёв `mid_block`, а не для полного U-Net.

С чем сравнивается предлагаемый метод

Скалярная квантизация

Scalar PTQ — равномерная сетка и независимое округление весов.

Q-Diffusion-like — калибровка сетки по ошибке восстановления выхода блока.

PTQ4DM-like — timestep-aware калибровка и reconstruction objective.

BitsFusion-lite — разная битность слоёв при заданном среднем бюджете.

Векторная квантизация

Vanilla VQ — один кодбук; быстрый базовый вариант.

AQUATIC-Diff-like — аддитивное представление несколькими кодбуками и калибровка по активациям.

VQDM — несколько кодбуков, activation-aware функционал и совместный beam search.

Like/lite — адаптации к единому no-fine-tuning протоколу, а не полные репродукции исходных методов.

От совместного поиска к остаточной квантизации

Общее представление вектора $w \in \mathbb{R}^d$ — сумма кодовых слов:

$$\widehat{w} = \sum_{m=1}^{M} C_m[z_m].$$

C_m — кодбук стадии m; z_m — индекс выбранного вектора.

VQDM: совместный выбор

Комбинация $(z_1, \ldots, z_M)$ выбирается через **beam search**.

Точный, но дорогой поиск при росте числа кодбуков и слоёв.

RVQ-AW: последовательный выбор

Каждая стадия квантует **остаток**:

$$r_0 = w, \qquad r_m = r_{m-1} - C_m[z_m].$$

Компромисс: потенциальная потеря точности из-за жадного выбора в обмен на более дешёвое построение.

Как RVQ учитывает активации

X — матрица калибровочных входов слоя; $\Delta W = W - \widehat{W}$; $G = X^\top X$.

$$\mathcal{L}(\widehat{W}) = \left\| X \Delta W^\top \right\|_F^2 = \mathrm{tr}\left(\Delta W \, G \, \Delta W^\top\right).$$

Минимизируется ошибка выхода слоя, а не только расстояние между исходными и квантизованными весами.

Разные размеры K_m

Ёмкость кодбуков перераспределяется между стадиями при близком общем битовом бюджете.

$$b_{\text{index}} = \frac{1}{d} \sum_m \log_2 K_m.$$

Full-G recoding

После построения кодбуки фиксируются. Coordinate descent уточняет **индексы** по полной G, учитывая взаимодействия между короткими блоками.

Hadamard

Ортогональное перемешивание координат перед RVQ. Применяется не безусловно: эффект зависит от конфигурации.

Recoding не является fine-tuning: на этом шаге меняются только дискретные индексы.

Экспериментальный протокол и метрики

Одинаковые условия

96 изображений на вариант; одинаковые prompts, seed и сэмплирование.

Калибровка: фиксированные запросы и шаги диффузии.

Скалярные методы: **2, 3, 4 бита**. Векторные целевые профили: **2.15, 3.15, 4.15 bpp**.

bpp учитывает индексы и кодбуки в расчёте на квантуемый вес.

T_q — время квантизации с калибровкой, **не время инференса**.

Как оценивается результат

CLIP I-I ↑ — семантическое сходство с результатом исходной модели.

LPIPS ↓ — перцептивное расстояние до того же результата.

CLIP T-I ↑ — соответствие изображения тексту.

PSNR, SSIM ↑ — пиксельное и структурное сходство.

$$\text{Score} = \text{CLIP I-I} - \text{LPIPS}.$$

Score используется для компактного ранжирования; выводы проверяются по совокупности метрик.

Результат: RVQ-AW ближе всех к VQDM

18 слоёв `mid_block`; три лучших метода по Score для каждого профиля.

Профиль	Метод	bpp	Score ↑	T_q, с ↓
≈ 2	VQDM	2.02	**0.586**	1857.1
	RVQ-AW	2.03	0.564	604.2
	BitsFusion-lite	2.05	0.468	88.4
≈ 3	VQDM	3.02	**0.721**	2846.8
	RVQ-AW	3.02	0.704	992.8
	Vanilla VQ	3.01	0.617	1.91
≈ 4	VQDM	4.03	**0.825**	3314.0
	RVQ-AW	4.03	0.786	1400.0
	Vanilla VQ	4.00	0.737	1.57

RVQ-AW — второе место по Score во всех трёх профилях.
Разрыв с VQDM — 0.017–0.039 Score. Зафиксированный wall-clock ниже в 2.4–3.1 раза, но аппаратные конфигурации запусков различались.

Что показали промежуточные проверки

Проверка	Постановка	Наблюдение
Разные K_m	10 Linear, noH, $d = 8$	При почти равном bpp Score вырос $0.5682 \to 0.6100$ для профиля 2.15 и $0.7076 \to 0.7236$ для 3.15.
Full-G recoding	Быстрый совмещённый sweep	Внутренний функционал уменьшился в среднем на **47.53%**. Внешние метрики менялись неоднозначно; нужен изолированный повтор.
Hadamard	10 Linear, $K = 256$, без recoding	H16 дал $+0.014$ Score при 3.15 bpp; при 2.15 и 4.15 лучшим был noH.
Размерность d	Старый совмещённый pipeline	При $K = 256$ вариант $d = 16$ проиграл $d = 8$ по качеству и потребовал почти вдвое больше времени.
Local recode	10 Linear, совмещённый перебор	Уточнение между стадиями выиграло лишь **2 из 20** парных сравнений; среднее Δ Score $= -0.0408$.

Главный положительный сигнал — разные K_m по стадиям. Текущий кандидат: $d = 8$, stage-wise K_m, local recode отключён; Hadamard и full-G recoding требуют факторной перепроверки.

Текущий вклад и следующий этап

Последовательная RVQ сохраняет большую часть преимущества VQDM по Score без совместного beam-search поиска.

Что сделано

Единый **no-fine-tuning протокол** для скалярных и векторных методов.

Кандидат **RVQ-AW**: activation-aware остаточная квантизация, распределение ёмкости стадий и recoding.

Сравнение при трёх битовых бюджетах и проверки отдельных гипотез.

Что проверить дальше

Контролируемый совместный перебор K, d, **Hadamard и recoding**.

Развитие timestep-aware калибровки и переход от `mid_block` к **полному U-Net**.

FID/clean-FID на большем числе изображений, preference-метрика, память и latency. Fine-tuning и distillation — отдельная линия экспериментов.

Область текущих выводов: `mid_block` и 96 изображений на вариант. T_q не нормирован по GPU; ускорение инференса из него не следует.

Метрики по каждому профилю

Профиль	Метод	bpp	CLIP I-I	CLIP T-I	LPIPS	Score
≈ 2	VQDM	2.02	0.831	0.305	0.244	0.586
	RVQ-AW	2.03	0.819	0.305	0.254	0.564
	BitsFusion-lite	2.05	0.768	0.312	0.300	0.468
≈ 3	VQDM	3.02	0.885	0.308	0.164	0.721
	RVQ-AW	3.02	0.879	0.308	0.175	0.704
	Vanilla VQ	3.01	0.828	0.319	0.212	0.617
≈ 4	VQDM	4.03	0.926	0.310	0.101	0.825
	RVQ-AW	4.03	0.911	0.311	0.125	0.786
	Vanilla VQ	4.00	0.881	0.317	0.144	0.737

Лидерство по Score не означает лидерства по CLIP T-I: сходство с исходной моделью и соответствие тексту — разные критерии.

Битовый бюджет и итоговые профили RVQ-AW

Стоимость индексов для вектора из d весов:

$$b_{\text{index}} = \frac{1}{d} \sum_{m=1}^{M} \log_2 K_m.$$

Фактический bpp дополнительно учитывает хранение кодбуков.

Целевой bpp	Hadamard	$(K_1, \ldots, K_M)$	d	Факт. bpp
2.15	noH	$[64, 1024]$	8	2.03
3.15	H32	$[128, 256, 512]$	8	3.02
4.15	H16	$[512, 512, 128, 128]$	8	4.03

Чистый тест Hadamard и итоговый выбор проводились в разных постановках: fixed K без recoding на 10 Linear против stage-wise K с recoding на 18 слоях. Поэтому различие оптимальных блоков не является противоречием, но взаимодействия нужно проверить в едином факторном эксперименте.