Квантизация диффузионных моделей машинного обучения

Краткий отчёт о проделанной работе

Подъяблонский Егор Петрович, ВМК МГУ, 2026

1. Задача исследования

Диффузионные модели обеспечивают высокое качество генерации изображений, но требуют значительного объёма памяти для хранения весов и больших вычислительных ресурсов. Цель работы состоит в исследовании post-training quantization для Stable Diffusion 1.5 и построении векторного метода, который сохраняет качество сильного VQDM, но избегает его наиболее дорогой части — совместного поиска комбинаций кодовых слов.

Основной объект экспериментов — U-Net модели Stable Diffusion 1.5. На текущем этапе квантуется `mid_block`: полный набор из 18 Linear/Conv2d-слоёв, а также VQDM-style набор из 16 слоёв, в котором исключены две проекции `time_emb_proj`. Квантуются только веса; последующий fine-tuning модели не применяется.

2. Экспериментальный протокол

Для всех методов используются одинаковые prompts, seed, параметры сэмплирования и набор из 96 изображений на один вариант. Скалярные методы сравниваются при 2, 3 и 4 битах на вес. Для векторных методов задаются целевые профили 2.15, 3.15 и 4.15 bpp; фактическая битность пересчитывается с учётом индексов и хранения кодбуков.

Калибровочные активации собираются на фиксированном наборе текстовых запросов и шагов диффузии. Они используются для оценки того, насколько ошибка в конкретном весе влияет на выход слоя. Благодаря этому сравниваются не только приближения весовой матрицы, но и их поведение на характерных входах модели.

3. Метрики

- **CLIP I-I** ↑ — семантическое сходство изображений исходной и квантизованной моделей.
- **LPIPS** ↓ — перцептивное расстояние между теми же изображениями.
- **CLIP T-I** ↑ — соответствие сгенерированного изображения исходному текстовому запросу.
- **PSNR и SSIM** ↑ — пиксельное и структурное сходство с результатом исходной модели.
- **bpp** — фактическое число бит на один квантуемый вес; T_q — время построения квантизованного представления с необходимой калибровкой.

Для компактного ранжирования используется

$$\text{Score} = \text{CLIP}_{I-I} - \text{LPIPS}.$$

Эта величина одновременно поощряет семантическое сходство и штрафует перцептивное расхождение, но окончательные выводы проверяются по всем метрикам, а не только по Score.

Все приведённые ниже результаты относятся к единому no-fine-tuning протоколу на mid-block. Это позволяет сравнивать алгоритмы в одинаковых условиях, но пока не является оценкой квантизации полного U-Net.

4. Рассмотренные базовые методы

Скалярная квантизация

- **Scalar PTQ.** Каждый вес независимо округляется к ближайшему уровню равномерной сетки. Метод практически не требует обучения и служит нижней контрольной точкой, но не учитывает распределение активаций и структуру диффузионной модели.

- **Q-Diffusion-like.** Диапазоны и параметры скалярной сетки выбираются на калибровочных данных с учётом ошибки восстановления выхода блока. Это делает квантизацию чувствительной к реальному прохождению сигнала через диффузионную модель.

- **PTQ4DM-like.** Используются timestep-aware калибровочные данные, послойная или поблочная политика настройки и reconstruction objective. В отличие от обычной PTQ, калибровка учитывает разные уровни шума в процессе денойзинга.

- **BitsFusion-lite.** Слоям назначается разная скалярная битность при заданном среднем bpp: чувствительные слои получают больше бит, устойчивые — меньше. В эксперименте используется calibration-only версия без обучаемой distillation-части исходного метода.

Векторная квантизация

- **Vanilla VQ.** Короткий вектор весов заменяется ближайшим вектором одного кодбука. Метод очень быстро строится, но единственный индекс ограничивает выразительность аппроксимации.

- **AQUATIC-Diff-like.** Используется аддитивное представление несколькими кодбуками и калибровка по активациям. Реализованная версия проверяет основную codebook-идею в общем протоколе, но не включает все обучаемые процедуры полной AQUATIC-Diff.

- **VQDM.** Весовой вектор представляется суммой кодовых слов из нескольких кодбуков. Индексы выбираются совместно с помощью beam search, а качество комбинации оценивается activation-aware функционалом. VQDM даёт наиболее точную аппроксимацию среди базовых методов, однако стоимость поиска быстро растёт с числом кодбуков и квантуемых слоёв.

5. Интерпретация набора бейзлайнов

Scalar PTQ показывает нижнюю границу сложности и качества. Q-Diffusion-like и PTQ4DM-like оценивают пользу diffusion-aware калибровки. BitsFusion-lite проверяет неравномерное распределение скалярного битового бюджета. Vanilla VQ является нижним векторным бейзлайном, AQUATIC-Diff-like — более содержательным аддитивным вариантом, а VQDM задаёт верхнюю точку качества для activation-aware многокодбуковой квантизации.

Суффиксы *like/lite* означают адаптацию основной идеи статьи к SD1.5 и единому no-fine-tuning протоколу. Результаты таких вариантов не следует трактовать как полную репродукцию обучаемых версий исходных методов.

6. Предлагаемый activation-aware RVQ

Пусть фрагмент весов представлен вектором $w \in \mathbb{R}^d$. В residual vector quantization он аппроксимируется суммой кодовых слов из последовательности кодбуков:

$$\hat{w} = \sum_{m=1}^{M} C_m[z_m], \qquad r_0 = w, \qquad r_m = r_{m-1} - C_m[z_m].$$

Каждая стадия квантует остаток предыдущей. В VQDM комбинация $(z_1, \ldots, z_M)$ выбирается совместно с beam search; в RVQ индексы находятся последовательно. Такая жадность может ухудшать качество, зато вычислительная стоимость растёт существенно медленнее и позволяет исследовать больше кодбуков и профилей.

Activation-aware функционал

Для слоя с весами W и матрицей калибровочных входов X минимизируется ошибка выхода слоя:

$$\mathcal{L}(\hat{W}) = \|X(W - \hat{W})^\top\|_F^2 = \mathrm{tr}\Big((W - \hat{W})X^\top X(W - \hat{W})^\top\Big).$$

В отличие от weight-only VQ, здесь одинаковые по норме ошибки весов могут иметь разную стоимость: матрица $X^\top X$ усиливает направления, которые чаще и сильнее используются активациями.

Распределение размера кодбуков по стадиям

Вместо одинакового K для всех стадий используются значения $K_1, \ldots, K_M$. Битовая стоимость индексов равна

$$b_{\text{index}} = \frac{1}{d} \sum_{m=1}^{M} \log_2 K_m.$$

Поэтому ёмкость можно перераспределять между ранними и поздними стадиями почти без изменения общего бюджета. Это отличается от простого увеличения всех кодбуков, которое автоматически повышает bpp.

Ортогональное преобразование Hadamard

Перед RVQ координаты блока могут быть перемешаны ортогональной матрицей Hadamard. Норма вектора при этом сохраняется, но меняется геометрия дискретной задачи: энергия и корреляции распределяются между координатами, что иногда облегчает работу коротких кодовых слов. Преобразование не включается безусловно, поскольку его эффект зависит от битового профиля и размера блока.

Post-RVQ recoding по полной матрице $X^\top X$

При обучении кодбуков activation-aware функционал обрабатывается по коротким блокам. После этого кодбуки фиксируются, а дискретные индексы дополнительно уточняются coordinate descent с использованием полной матрицы $X^\top X$. Это позволяет учитывать взаимодействия между блоками. Такой шаг не является fine-tuning: веса модели и векторы кодбуков не обучаются градиентно, изменяются только индексы уже построенного представления.

Итоговая рабочая версия: $d = 8$, разные K_m по стадиям, full-$X^\top X$ recoding и отключённый local recode. Hadamard выбирается отдельно для каждого bpp-профиля.

7. Промежуточные результаты

Ниже приведено сравнение на полном наборе из 18 слоёв mid-block. Для каждого битового профиля показаны VQDM, предлагаемый RVQ-AW и лучший следующий бейзлайн по Score.

Профиль	Метод	bpp	CLIP I-I	CLIP T-I	LPIPS	Score	T_q, с
2	VQDM	2.02	0.831	0.305	0.244	**0.586**	1857.1
2	**RVQ-AW**	2.03	0.819	0.305	0.254	0.564	604.2
2	BitsFusion	2.05	0.768	0.312	0.300	0.468	88.4
3	VQDM	3.02	0.885	0.308	0.164	**0.721**	2846.8
3	**RVQ-AW**	3.02	0.879	0.308	0.175	0.704	992.8
3	Vanilla VQ	3.01	0.828	0.319	0.212	0.617	1.91
4	VQDM	4.03	0.926	0.310	0.101	**0.825**	3314.0
4	**RVQ-AW**	4.03	0.911	0.311	0.125	0.786	1400.0
4	Vanilla VQ	4.00	0.881	0.317	0.144	0.737	1.57

Результаты проверок отдельных гипотез

Проверка	Наблюдение
Hadamard	H16 улучшил Score на 0.014 в чистом эксперименте для 3.15 bpp, но при 2.15 и 4.15 лучшим остался вариант без преобразования.
Full-$X^\top X$ recoding	Внутренний функционал уменьшился в среднем на 47.53%; влияние на внешние image-метрики оказалось положительным в среднем, но не для каждой конфигурации.
Размерность d	При $K = 256$ вариант $d = 16$ проиграл $d = 8$ по качеству и потребовал почти вдвое больше времени.
Local recode	Уточнение после промежуточных стадий выиграло только 2 из 20 парных сравнений; среднее изменение Score составило -0.0408.

Итоговые профили RVQ-AW

Цель	Hadamard	$(K_1, \ldots, K_M)$	d	Фактический bpp
2.15	noH	$[64, 1024]$	8	2.03
3.15	H32	$[128, 256, 512]$	8	3.02
4.15	H16	$[512, 512, 128, 128]$	8	4.03

8. Основной вывод и дальнейшая работа

RVQ-AW занимает второе место во всех трёх профилях. Разрыв с VQDM по Score составляет 0.022, 0.017 и 0.039 для профилей около 2, 3 и 4 bpp соответственно. При этом RVQ-AW превосходит остальные проверенные методы; например, около 3 bpp он достигает Score 0.704 против 0.617 у следующего бейзлайна. Таким образом, последовательная остаточная квантизация сохраняет большую часть преимущества VQDM без совместного AVQ/beam-search поиска.

Следующий этап исследования — контролируемый совместный перебор K, d, Hadamard и вариантов recoding, timestep-aware калибровка, переход от mid-block к полному U-Net и оценка на более сильных генеративных метриках. Fine-tuning или distillation следует рассматривать отдельно, чтобы не смешивать post-training и обучаемые методы.